

Descripción del dataset:

El dataset se construyó íntegramente mediante web scraping del portal MercadoLibre Inmuebles, la mayor plataforma de avisos inmobiliarios de Argentina. Se relevaron departamentos usados en venta en los 47 barrios de la Ciudad Autónoma de Buenos Aires, obteniendo un total de 27.922 propiedades únicas. La extracción se realizó recorriendo cada barrio de forma independiente, lo que permitió alcanzar un volumen alto y, a la vez, garantizar la representación de toda la ciudad, desde barrios de gran oferta como Palermo, Belgrano, Caballito y Recoleta (con alrededor de 2.000 propiedades cada uno) hasta barrios más pequeños del sur y el oeste con unas pocas decenas de avisos.

Cada propiedad cuenta con 93 variables, capturadas tanto del listado como de la ficha de detalle de cada aviso. Estas variables abarcan una amplia diversidad de tipos de datos: numéricos continuos (precio en dólares, superficie en metros cuadrados, expensas), numéricos discretos (ambientes, dormitorios, baños, cocheras, antigüedad), categóricos (barrio, orientación, disposición, tipo de departamento), dicotómicos (más de 40 columnas de amenities y características del tipo Sí/No, como pileta, gimnasio, ascensor, parrilla, seguridad o balcón), textuales (título y dirección del aviso) y geográficos. La mediana de precio del conjunto es de 130.000 dólares y la de superficie es de 57 metros cuadrados, valores consistentes con el mercado de departamentos usados de CABA.

El dataset fue posteriormente enriquecido con dos procesos adicionales. En primer lugar, se geocodificaron las direcciones de los avisos utilizando el normalizador oficial de USIG (Gobierno de la Ciudad de Buenos Aires), obteniendo las coordenadas de latitud y longitud de 22.912 propiedades (el 82% del total; el resto no pudo geocodificarse por presentar direcciones incompletas o no normalizables). En segundo lugar, a partir de esas coordenadas se incorporaron variables de entorno y localización: la distancia de cada propiedad a la estación de subte más cercana, la distancia a los principales polos de centralidad de la ciudad, y la asignación de cada propiedad a una sub-zona geográfica dentro de su barrio, definida mediante clustering espacial (198 sub-zonas en total). Las fuentes externas utilizadas para este enriquecimiento son el normalizador de direcciones de USIG y el dataset oficial de estaciones de subte publicado por BA Data (portal de datos abiertos del Gobierno de la Ciudad).

Contexto y situación de negocio:

La idea de negocio es un fondo de inversión inmobiliario que opera en 47 barrios de CABA. La hipótesis de negocio que queremos plantear es la siguiente: hay dos departamentos ubicados en el mismo barrio y en la misma zona, porque no es lo mismo palermo chico que palermo soho, y que están a la venta aproximadamente por el mismo precio. El objetivo es encontrar que uno de esos dos departamentos ofrece más comodidades que el otro aunque estén publicados al mismo precio, como pileta, gimnasio, SUM, etc, porque el mercado no siempre les asigna a esas comodidades un valor extra. Como describimos anteriormente, este análisis se nos puede facilitar bastante porque nuestro dataset cuenta con más de 80 variables por propiedad, entre ellas decenas de amenities.

Para elegir con criterio, el fondo tiene su propio índice de confort con puntaje del uno al diez calculado para cada propiedad. Este índice se conforma con 3 elementos: 1. Infraestructura básica como gas, aire acondicionado, internet, agua, entre otros, que representa un 45% en la ponderación del índice, ya que es lo que define si una propiedad es habitable en condiciones normales. 2. Amenities y servicio del edificio como pileta, gimnasio, sauna, o similares, que explica un 30% de la ponderación del índice de confort, porque mejoran mucho la calidad de vida, comodidad y precio de reventa, pero no son indispensables para una vivienda normal como la infraestructura básica. 3. Atributos propios del departamento, como por ejemplo en qué piso está ubicado, si es frente o contrafrente, si tiene balcón o terraza, etc, esto es no solo lo que tiene la propiedad sino cómo está posicionada dentro del edificio. Así, los atributos propios del departamento completarán lo que resta del índice con un peso del 25%, ya que tienen un peso real sobre el confort, tal como la luz y la vista. Cada uno de estos elementos suma puntos al índice, cabe destacar que lo más esencial como gas o agua tiene más ponderación.

Es importante entender que el barrio o la ubicación en sí no forma parte del índice, ya que la idea es comparar entre departamentos de la misma zona. Por último se va a comparar este índice de confort con el precio del metro cuadrado de propiedades similares ubicadas en la misma zona, para detectar si el confort que ofrece la propiedad está sistemáticamente por encima de lo que el precio por metro cuadrado de esa zona sugiere.

La unidad de comparación entre propiedades es la sub-zona, entendida como una subdivisión geográfica dentro de cada barrio, construida a partir de la ubicación de las propiedades. Esto responde a que un barrio no es homogéneo: no es lo mismo Palermo Soho que Palermo Hollywood. No obstante, para que la comparación sea estadísticamente confiable, se establece un mínimo de propiedades por sub-zona, cuando una sub-zona no alcanza ese mínimo, la comparación se realiza tomando el barrio completo como nivel de respaldo, garantizando así que siempre exista una base de comparación robusta.

Además de las características internas de cada propiedad, el análisis incorpora variables de su entorno urbano que también influyen en el valor. Concretamente, se mide la accesibilidad

al transporte público (distancia a la estación de subte más cercana) y la cercanía a las zonas de centralidad de la ciudad (distancia a los principales polos de actividad). Estas variables no forman parte del índice de confort, sino que se utilizan como una capa complementaria, ayudan a explicar por qué determinadas zonas sostienen precios más altos y permiten distinguir una oportunidad genuina de un caso en que el menor precio se explica simplemente por una peor ubicación. De este modo, el análisis separa el valor asociado a lo que la propiedad ofrece puertas adentro del valor asociado a dónde está ubicada.

Un hallazgo preliminar relevante surge de la variable de centralidad. Contrario a lo que ocurre en muchas ciudades, en CABA la cercanía al microcentro no explica el precio por metro cuadrado: los barrios de mayor valor (Palermo, Belgrano, Núñez, Colegiales) se ubican en el corredor norte, a varios kilómetros del centro geográfico, mientras que zonas plenamente céntricas como Constitución o La Boca se encuentran entre las más económicas. Esto responde a un fenómeno de transición urbana en curso: el eje corporativo y de servicios de la ciudad viene desplazándose históricamente hacia el norte, consolidando esa franja como un nuevo polo laboral y residencial premium, en detrimento del microcentro tradicional. Por este motivo, si bien la distancia a la centralidad se calcula e incorpora al dataset, se asume que su poder explicativo sobre el precio es limitado, y se prioriza la comparación dentro de cada zona (donde el confort y los atributos de la propiedad son los factores determinantes) por sobre la comparación entre zonas según su ubicación.

Preguntas clave según los 4 niveles de análisis:

Nivel descriptivo (Que paso / Que está pasando):

- ¿Cómo se distribuye el índice de confort dentro de cada zona, y cuanto pesa cada elemento (infraestructura básica, amenities y servicios, atributos propios) por separado en ese promedio?
- ¿Qué tan completos están los datos de las columnas de amenities? ¿Si en una propiedad un amenity como gimnasio tiene la columna vacía se interpreta como dato faltante, o como ausencia del amenity? En estos casos hay que medir cuánto de estos datos son faltantes y cuantos ausentes del amenity, para que no afecte a la confiabilidad del índice.
- ¿Existen propiedades con perfiles contradictorios? Por ejemplo una propiedad con amenities de lujo como pileta, sauna, cancha de paddlec, pero sin mucha infraestructura básica, como agua, gas, etc. Si estas existen hay que ver si el índice las penaliza más que una simple suma.

- ¿El índice de confort tiene una dependencia con el tamaño de la propiedad, o son cosas independientes? Se podría validar el supuesto de que dos departamentos del mismo tamaño tengan un índice de confort muy distinto.

Nivel diagnóstico (Por que paso / Por que sucede):

- ¿Los pesos del índice que se asignaron a mano, se sostienen con los datos reales? Si se hace una regresión de precio por metro cuadrado contra cada elemento por separado, ¿la infraestructura básica realmente explica precios más elevados que los amenities, o el mercado paga más por la belleza del departamento que por lo esencial?
- ¿Las expensas se comportan como esperamos, o sea a mas confort expensas más caras? Si una propiedad tiene un gran confort y expensas bajas para ese confort, ¿es realmente un gran negocio o puede ser una señal de que el edificio no mantiene bien los amenities?
- ¿La relación entre el índice de confort y el precio del metro cuadrado tiene la misma fuerza en todos los segmentos de precio de una misma zona, o el confort se paga más caro en las propiedades de gama más alta que en las de gama media? Esto quiere decir que si se toma una propiedad por encima de la media de precio por metro cuadrado y una por debajo, en una misma zona, y se mide cuantos dólares de metro cuadrado representa cada punto del índice, ¿este valor es parecido en las dos propiedades, o es más elevado en las propiedades más caras? Esto nos sirve para priorizar las oportunidades de inversión según en qué segmento de precio se encuentran, en vez de tratar a todas las propiedades por igual.
- ¿Cuánto del precio por metro cuadrado de una zona se explica por su accesibilidad al transporte y su cercanía a la centralidad? Al comparar propiedades con gap de confort positivo, ¿ese gap se sostiene cuando se controla por la ubicación, o parte de las 'oportunidades' detectadas en realidad se explican por estar en zonas menos accesibles?

Nivel predictivo (Que pasara):

- Con la curva de referencia por zona de precio del metro cuadrado según el índice de confort, ¿se puede marcar automáticamente como oportunidad cualquier aviso nuevo que se publica, o se debería hacer un research más profundo?

- De los tres elementos que se tienen en cuenta para el índice, ¿cuál es el que está más “regalado” frecuentemente? Esto le da una visión al fondo de donde concentrar la búsqueda.
- Si repetimos el scraping más adelante, ¿el gap de confort de las propiedades que hoy se detectan como oportunidad, se reduce con el tiempo o se mantiene? Esto va a mostrar si el índice mide algo real o solo ruido.
- Al priorizar oportunidades, ¿conviene ponderar de forma distinta una propiedad subvaluada bien ubicada (cerca de transporte y centralidad) frente a una subvaluada en una zona periférica, dado que la primera tiene mayor liquidez y potencial de revalorización?

Nivel prescriptivo (Que deberíamos hacer):

- Definir un umbral de gap de confort + eficiencia de las expensas para definir si una propiedad pasa directo al comité de inversión sin revisión manual, o si se necesita evaluar manualmente.
- ¿En qué zona conviene que el fondo concentre sus análisis e inversiones, según donde el gap promedio sea mayor o más consistente?
- Recomendación de recalibración de las ponderaciones del índice. Dado que los pesos del índice son una decisión nuestra, habría que proponer cada cuánto conviene re-testear esos pesos contra los datos (por ejemplo, si el bloque de atributos de la propiedad empieza a explicar más precio de lo esperado, ajustar la ponderación).

KPIs

KPI	¿Qué mide?	¿Cómo se calcula?
Índice de Confort (1-10)	Nivel de equipamiento y posicionamiento de una propiedad.	Suma ponderada de 3 bloques con puntuación normalizada del 1 al 10: infraestructura básica 45% + amenities del edificio 30% + atributos de la propiedad 25%. La ubicación no

		pertenece al cálculo.
Tasa de completitud	Qué tan confiable es el índice en una propiedad en específico.	Porcentaje de columnas de amenities con dato real (no nulo) sobre el total de columnas consideradas. Sirve para evaluar qué porcentaje del índice de confort está bien calculado.
Peso empírico por bloque	Si los pesos calculados a mano se pueden contrastar con evidencia.	Coefficiente de cada bloque en una regresión de precio por metro cuadrado por zona. Si es necesario se pueden recalibrar las ponderaciones.
Precio por metro cuadrado por zona	El precio normal de esa zona usado como vara de comparación.	Mediana de precio por metro cuadrado en propiedades comparables, misma zona, tamaño similar, etc.
Gap de confort	Cuánto confort de más o de menos ofrece una propiedad respecto a lo que su precio sugeriría en su zona.	Residuos de precio por metros cuadrados en función del índice de confort, calculado por zona.
Confort por segmento de precio	Si el confort se paga más fuerte en las propiedades caras que en las de precio medio.	Pendiente de precio por metro cuadrado en función del índice de confort, calculada por separado en propiedades de gama alta y gama media, por encima o por debajo de la mediana del precio del metro cuadrado de la zona.

Eficiencia de expensas	Si el confort de la propiedad se paga barato o caro por mes.	Índice de confort / expensas o expensas por metro cuadrado.
Ranking de oportunidades	Las mejores oportunidades para pasar al comité de inversión.	Top n propiedades por zona, ordenadas por gap de confort positivo, ponderadas por el confort por segmento de precio, y filtradas por buena tasa de completitud.
Índice de accesibilidad	Qué tan bien ubicada está una propiedad respecto al transporte y la centralidad	Combinación de la distancia a la estación de transporte más cercana y la distancia a la zona de centralidad, normalizada.
Gap de confort ajustado por ubicación	El gap de confort una vez descontado el efecto de la ubicación	Residuo del precio por m ² en función del índice de confort y las variables de entorno, por zona

Hipótesis y alcance:

Hipótesis 1:

El mercado no incorpora completamente el valor del confort en el precio de publicación. Es decir, dentro de una misma zona, existen propiedades con un índice de confort significativamente superior al de sus comparables que, sin embargo, se publican a un precio por metro cuadrado similar o inferior. Estas propiedades constituyen oportunidades de inversión subvaluadas.

Hipótesis 2:

Un barrio no es una unidad homogénea de precios: existe una variación significativa del precio por metro cuadrado entre las distintas sub-zonas de un mismo barrio. Por lo tanto,

comparar propiedades a nivel de sub-zona produce una vara de referencia más precisa que compararlas a nivel de barrio completo.

Hipótesis 3:

Parte de la variación de precios entre zonas que a primera vista podría interpretarse como "confort no valorado" se explica en realidad por variables de entorno, principalmente la accesibilidad al transporte y la cercanía a la centralidad. En consecuencia, incorporar estas variables permite depurar las oportunidades detectadas, distinguiendo las genuinas de aquellas cuyo menor precio responde a una peor ubicación.

Objetivo principal del análisis:

El objetivo es detectar de forma sistemática propiedades cuyo nivel de confort, entendido como el equipamiento y el posicionamiento del departamento, se ubica por encima de lo que su precio por metro cuadrado sugeriría dentro de su zona, con el fin de identificar oportunidades de inversión potencialmente subvaluadas. El análisis combina dos miradas complementarias: por un lado, un índice de confort propio construido a partir de las características internas de cada propiedad (infraestructura básica, amenities del edificio y atributos del departamento); por otro, un conjunto de variables de entorno (accesibilidad al transporte público y cercanía a las zonas de centralidad de la ciudad) que ayudan a explicar por qué ciertas zonas sostienen los precios que sostienen, y a distinguir las oportunidades reales del ruido asociado a la ubicación.

Alcance:

El análisis se circunscribe a los 47 barrios de la Ciudad Autónoma de Buenos Aires, y se limita a departamentos usados en venta, dejando fuera del estudio otras tipologías como casas y PH, así como las operaciones de alquiler y los emprendimientos en pozo. Un punto central del alcance es que el trabajo opera sobre el precio de publicación de los avisos, no sobre el precio de venta efectivo, dato que no es de acceso público. En consecuencia, lo que el análisis detecta son publicaciones cuyo precio resulta bajo en relación con las características y el confort que ofrecen, y no necesariamente propiedades que vayan a venderse por debajo de su valor; esta distinción se asume de forma explícita como una limitación metodológica del enfoque. Asimismo, el análisis se construye sobre una foto del mercado en un momento puntual (los datos relevados en el proceso de scraping) y no sobre una serie temporal, por lo que las conclusiones describen el estado del mercado en ese corte y no su evolución. Geográficamente, la unidad de comparación es la sub-zona dentro

de cada barrio (con el barrio como respaldo cuando la sub-zona no alcanza un mínimo de propiedades), según se detalla en el contexto.

Como línea de trabajo para las siguientes entregas, se propone reemplazar o complementar la variable estática de distancia a la centralidad por una medida del dinamismo de cada zona, es decir, de su tendencia de crecimiento o decrecimiento en el tiempo. La lógica es que, para un fondo de inversión, resulta más valioso identificar hacia dónde se está desplazando el valor que constatar dónde se concentra hoy, ya que el objetivo es anticiparse a la revalorización. Se evaluarán al menos tres fuentes posibles para construir esta variable: (1) la comparación del precio por metro cuadrado de cada zona entre dos relevamientos sucesivos de scraping, que permitiría medir directamente la variación temporal; (2) los permisos de obra nueva georreferenciados publicados por BA Data, como proxy de las zonas en desarrollo activo; y (3) la proporción de propiedades de construcción reciente dentro de cada zona, calculable a partir de la antigüedad ya presente en el dataset actual, como señal de renovación del stock edilicio. Esta variable de dinamismo permitiría capturar fenómenos como la actual transición del eje laboral y residencial de la ciudad hacia el corredor norte, que la distancia a un punto de centralidad fijo no logra reflejar.

Definición del usuario final:

El usuario final es el analista de inversiones del fondo. Es quien, en el día a día, revisa el flujo de propiedades publicadas y arma el pipeline de oportunidades que luego eleva al comité de inversión. Su problema concreto es de volumen, existen decenas de miles de publicaciones activas en CABA y resulta inviable analizarlas todas manualmente. La herramienta le permite filtrar ese universo y quedarse con el subconjunto de propiedades que muestran un gap de confort positivo respecto a su zona, ordenadas por atractivo, para concentrar su análisis profundo solo donde tiene sentido. Un usuario secundario es el propio comité de inversión, que recibe las oportunidades ya filtradas y priorizadas para tomar la decisión final de compra, y que además se apoya en el análisis por zonas para definir dónde conviene que el fondo concentre su capital.